

Evaluación comparativa de SVM y DenseNet201 para la clasificación automática de enfermedades dermatológicas

Christian Gutiérrez Gutiérrez · Alvaro Gutiérrez Burbano

Director: Víctor D. Díaz Suárez
Máster Universitario en Análisis y Visualización de Datos Masivos — UNIR

ÍNDICE

- 01 –Introducción y objetivos
- 02 - Normativa y datos
- 03 - SVM y DenseNet201
- 04 - Resultados y conclusiones

Introducción - 01

Motivación

Cáncer de piel: una emergencia de salud pública en expansión

Incidencia global creciente Más de 330.000 nuevos casos de melanoma al año en el mundo (Langselius, Rumgay y de Vries, 2025).

El tiempo es supervivencia Detectado en fase localizada, el melanoma supera el 99% de supervivencia relativa a 5 años (American Cancer Society, 2026).

Cuello de botella clínico 131 días de espera media para una primera consulta de dermatología en España; la saturación es aún mayor en contextos como Ecuador.

Introducción · 02

Planteamiento del trabajo

Una comparativa, no una carrera por el accuracy – el criterio de éxito es clínico, no estadístico

Dos paradigmas frente a frente Machine Learning tradicional (SVM) frente a Deep Learning con Transfer Learning (DenseNet201) sobre el mismo problema.

La métrica que manda: Sensibilidad Un falso negativo —lesión maligna etiquetada como benigna— tiene un coste clínico muy superior al de un falso positivo.

Medición robusta F1-Score y AUC-ROC como respaldo, dado el fuerte desbalance de clases del dataset HAM10000.

Contexto - 03

HAM10000

Código	Diagnóstico	N imágenes	%	Malignidad
nv	Nevus melanocítico	6.705	66,9%	Benigno
mel	Melanoma	1.113	11,1%	Maligno
bkl	Queratosis benigna	1.099	11,0%	Benigno
bcc	Carcinoma basocelular	514	5,1%	Maligno
akiec	Queratosis actínica	327	3,3%	Maligno
vasc	Lesión vascular	142	1,4%	Benigno
df	Dermatofibroma	115	1,1%	Benigno

| Contexto - 04

| Estado del arte

El ojo clínico más entrenado también se equivoca – variabilidad entre especialistas y fatiga diagnóstica

De SVM a las redes profundas La literatura documenta el tránsito del Machine Learning clásico hacia arquitecturas de Deep Learning en clasificación dermatoscópica (Bechelli y Delhommelle, 2022).

No solo precisión Los sistemas deben ser interpretables y computacionalmente viables para integrarse en la práctica clínica real.

CDSS: apoyo, no sustitución Un Sistema de Soporte a la Decisión Clínica no reemplaza al dermatólogo: reduce tiempos y homogeneiza el cribado inicial.

Objetivos · 05

Objetivos del TFM

Determinar el modelo óptimo y escalable para el cribado dermatológico –
comparando Machine Learning tradicional y Deep Learning

Datos EDA sobre HAM10000 para identificar sesgos y distribuciones de clase; pipeline de preprocesamiento y balanceo (sobre y submuestreo).


Modelado Extracción paramétrica y SVM frente a Transfer Learning con DenseNet201.

Evaluación Comparación con métricas clínicas —Sensibilidad, F1-Score, AUC-ROC— y contraste con trabajos relacionados.

Metodología · 06

CRISP-DM

adaptado a imágenes médicas



Marco normativo · 07

Marco legal y ético

Datos de salud, máxima protección – LOPDP, ARCSA y gobernanza de la IA

LOPDP (Ecuador, 2021) Los datos de salud son categoría sensible (Art. 25); HAM10000 está anonimizado y se distribuye bajo licencia académica abierta.


ARCSA / MSP Todo sistema de diagnóstico clínico recae bajo su supervisión; este TFM se plantea como Prueba de Concepto (PoC) académica, no como CDSS certificado.

Ética y sesgos demográficos Punto de partida para evaluar la representatividad del dataset frente a la diversidad fenotípica ecuatoriana (ver Limitaciones).

Datos · 08

El desbalance de clases

66,9% de las imágenes son nevus benignos (nv) – el resto de las 7 clases no supera individualmente el 12%



Datos · 09

Dos escenarios de datos

Partición estratificada por lesion_id – evita fuga de información entre imágenes de una misma lesión

Escenario 1 — Multiclase original 7 clases con el desbalance real ($\approx 4,1:1$ benigno:maligno); SMOTE aplicado solo dentro de la validación cruzada.

Escenario 2 — Binario balanceado Benigno vs. Maligno; submuestreo estratificado por lesión (1.954 vs. 1.954 imágenes).

Por qué dos escenarios Permite aislar el efecto del balanceo del dataset del efecto propio del algoritmo de clasificación.

Modelado · 10

SVM: pipeline tradicional

De 12.288 píxeles a 84 componentes – extracción paramétrica + PCA (95% de varianza retenida)

Preprocesamiento Imágenes 64×64 RGB aplanadas a vectores; estandarización y PCA (12.288 → 84 componentes, -99,3%).

Clasificador SVC con kernel RBF (C=1.0, gamma=scale, class_weight=balanced) y probability=True para AUC calibrado.

Balanceo por escenario Escenario 1: SMOTE sobre el entrenamiento. Escenario 2: sin SMOTE, dataset balanceado por submuestreo agrupado por lesión.

Resultados - 11

SVM

Métrica	Escenario 1 (multiclase)	Escenario 2 (binario)	Δ	Lectura clínica
Accuracy	68,15%	79,85%	+11,7 pts	Exactitud global
F1 Macro	48,34%	79,30%	+30,96 pts	Mejora en clases minoritarias
AUC-ROC	87,76%	86,43%	-1,3 pts	Discriminación estable
Sensibilidad Malignidad	64,5%	92,9%	+28,4 pts	Muchos menos falsos negativos
Balanced Accuracy	51,67%	79,39%	+27,7 pts	Rendimiento más equilibrado
MCC	0,456	0,614	+0,158	Mayor fiabilidad global
Balancear el dataset dispara la sensibilidad a la malignidad (64,5% → 92,9%) sin sacrificar el AUC-ROC				

| Modelado · 12

| DenseNet201: doble cabeza

Un backbone, dos tareas simultáneas – 18,1 millones de parámetros entrenables sobre ImageNet

Backbone DenseNet201 Preentrenado en ImageNet; los Dense Blocks maximizan el flujo de gradientes y reutilizan características.

Arquitectura de dos cabezas Cabeza A —triaje binario benigno/maligno— y Cabeza B —diagnóstico específico de 7 clases—; pérdida conjunta ponderada 50/50.

Entrenamiento 30 épocas, Adam ($\text{lr}=0.0001$), Weighted Cross-Entropy en la Cabeza B, Data Augmentation (flips y rotaciones $\pm 15^\circ$).

Resultados - 13

DenseNet201

Métrica	Escenario 1 (original)	Escenario 2 (balanceado)	Δ	Lectura clínica
Accuracy (Cabeza B)	90,36%	86,96%	-3,4 pts	El submuestreo penaliza clases raras
Recall Macro (Cabeza B)	87,78%	78,13%	-9,65 pts	Peor en Dermatofibroma y Vascular
F1 Macro (Cabeza B)	86,79%	79,71%	-7,08 pts	Coherente con el recall macro
Sensibilidad Malignidad (Cabeza A)	81,07%	90,03%	+8,96 pts	Falsos negativos: 74 $\rightarrow$ 39
Especificidad (Cabeza A)	96,34%	92,84%	-3,5 pts	Más derivaciones innecesarias
AUC-ROC (Cabeza A)	96,46%	96,50%	$\approx$ estable	El balanceo no altera la discriminación
El balanceo desplaza el punto de operación hacia mayor sensibilidad, no la capacidad de discriminación				

Resultados · 14

Comparativa

Dimensión	SVM (Esc. 2)	DenseNet201 (Esc. 2, Cabeza A)	Ventaja	Lectura
Accuracy global	79,85%	91,43%	DenseNet201	Mejor exactitud general
Sensibilidad (Recall Maligno)	92,9%	90,03%	SVM (+2,87 pts)	Único criterio donde gana SVM
Especificidad (Recall Benigno)	65,9%	92,84%	DenseNet201	SVM deriva a 1 de cada 3 sanos
Precisión (Maligno)	74,5%	92,63%	DenseNet201	Menos falsas alarmas
AUC-ROC	86,43%	96,50%	DenseNet201	Mayor capacidad de discriminación
Cohen's Kappa / MCC	0,593 / 0,614	0,829 / 0,829	DenseNet201	Mayor fiabilidad global
Coste computacional — SVM: 1,33 s entrenamiento / 0,25 ms por imagen · DenseNet201: 62,3 min / 13,35 ms por imagen				

| Conclusiones · 15

| Conclusiones

No existe un algoritmo absolutamente superior – la elección depende del recurso más escaso en el despliegue

Objetivos cumplidos Los 5 objetivos específicos —EDA, balanceo, SVM, DenseNet201 y comparación— quedan acreditados en la memoria.

SVM Escenario 2 Sensibilidad más alta (92,9%) a coste computacional casi nulo; ideal con escasa capacidad de cómputo, aunque deriva a muchos pacientes sanos.

DenseNet201 Escenario 2 Sensibilidad casi equivalente (90,03%) con especificidad, precisión, AUC-ROC, Kappa y MCC muy superiores; requiere más infraestructura.

Limitaciones · 16

Limitaciones del estudio

El dataset no refleja la diversidad fenotípica ecuatoriana – principal riesgo de sesgo del sistema

Sesgo fenotípico HAM10000 procede mayoritariamente de poblaciones europeas y australianas (Fitzpatrick I-III); Ecuador presenta predominancia de fototipos III-V.

Sin variables clínicas tabulares DenseNet201 procesa solo imágenes; no integra edad, sexo o localización pese a su correlación con la malignidad.

Infrarrepresentación y partición Subtipos como el melanoma acral lentiginoso están infrarrepresentados; el Escenario 1 de DenseNet201 no agrupó la partición por lesion_id.

| Trabajo futuro · 17

| Líneas de trabajo futuro

De la prueba de concepto al sistema desplegable

Muestreo asimétrico por cabeza Cada cabeza de DenseNet201 se entrenaría con un dataset distinto, resolviendo el trade-off entre escenarios.

Modelado multimodal Fusionar el vector de características visuales con una red densa que procese edad, sexo y localización anatómica.

Validación ecuatoriana y CDSS Arquitecturas alternativas (EfficientNet, Vision Transformers), validación multicéntrica local e integración en un CDSS real.

muchas gracias

Christian Gutiérrez Gutiérrez · Alvaro Gutiérrez Burbano
github.com/marzo27/UNIR_TFM_HAM10000