



Evaluación comparativa de SVM y DenseNet201 para la clasificación automática de enfermedades dermatológicas

Trabajo Fin de Máster · Máster Universitario en Análisis y Visualización de Datos Masivos / Visual Analytics and Big Data

Christian Marcelo Gutiérrez Gutiérrez · **Alvaro Marcelo Gutiérrez Burbano**

Director: Víctor D. Díaz Suárez

Escuela Superior de Ingeniería y Tecnología · Universidad Internacional de La Rioja · 2026



ÍNDICE

30 minutos

01 Introducción y contexto

4 min · Christian

02 Metodología

3 min · Christian

03 Comprensión de los datos

5 min · Christian

04 Preparación de los datos

3 min · Alvaro

05 Modelado

3 min · Alvaro

06 Evaluación y resultados

6 min · Alvaro

07 Conclusiones y prospectiva

2 min · Alvaro

01

Introducción y contexto

El problema clínico, el estado del arte y la pregunta de investigación

4 minutos · Expone: Christian

Un problema de salud pública con un cuello de botella logístico

La incidencia crece, el diagnóstico precoz decide el pronóstico y el sistema sanitario no llega a tiempo

+330.000

Nuevos casos de melanoma al año

en el mundo (Langselius et al., 2025)

> 99 %

Supervivencia relativa a 5 años

si se detecta en fase localizada (ACS, 2026)

131 días

Espera media a primera consulta

de dermatología (Min. Sanidad, 2025)

+250 %

Aumento de incidencia

de melanoma en la región andina (Zhou et al., 2026)

La variabilidad del diagnóstico visual

- Criterios heterogéneos entre especialistas y solapamiento morfológico entre lesiones benignas y malignas.
- El rendimiento clínico se degrada con la fatiga y la saturación asistencial.

La oportunidad: sistemas de soporte (CDSS)

- El algoritmo no sustituye al facultativo: lo potencia con una segunda opinión reproducible y disponible en segundos.
- Repositorios masivos abiertos como HAM10000 hacen viable entrenar y validar estos sistemas.

El diagnóstico precoz es el factor más determinante para la supervivencia — y es precisamente donde el sistema falla por saturación.

El planteamiento: no todos los errores cuestan lo mismo

La asimetría del coste clínico es la que fija el criterio de éxito de todo el trabajo

Falso negativo

Una lesión maligna clasificada como benigna.

Retrasa la intervención sobre un tumor que puede hacer metástasis. El coste es la vida del paciente. Es un error inasumible.

Falso positivo

Una lesión benigna marcada como sospechosa.

Genera una derivación o una prueba adicional. Consume recursos, pero es un coste recuperable.

Consecuencia sobre el diseño de la comparativa

Sensibilidad (Recall)

Métrica principal: proporción de lesiones malignas realmente detectadas.

F1-Score macro

Equilibra precisión y recall sin dejarse dominar por la clase mayoritaria.

AUC-ROC (OvR)

Capacidad de discriminación con independencia del umbral de decisión.

Accuracy

Se reporta solo como referencia secundaria: con desbalance severo, engaña.

Pregunta de investigación: ¿qué paradigma —ML clásico o Deep Learning— detecta más lesiones malignas sin degradar de forma inaceptable el resto de métricas?

Estado del arte: qué se ha hecho y qué hueco deja

Cinco trabajos de referencia sobre HAM10000 y arquitecturas comparables

Autor (año)	Dataset	Modelo	Métrica principal	Aportación / relación con este TFM
Bechelli y Delhommelle (2022)	Kaggle + HAM10000	ResNet50 / VGG16 vs. RF / SVM	Accuracy 83,6 %	DL supera a ML clásico en precisión global
Sönmez et al. (2023)	HAM10000	MobileNetV2 (mejor de 4 CNN)	Accuracy 80,79 %	Data augmentation frente al submuestreo de este TFM
Çevik y Zengin (2019)	HAM10000	VGGNET (CNN personalizada)	Accuracy 85,62 %	Valida ReLU + Adam, empleados también aquí
Sánchez Sánchez (2024)	HAM10000 (ISIC 2018)	Ensamblado EfficientNet + DenseNet121 + NASNet	BMA 0,7645	Antecedente más cercano: también prioriza recall en clases malignas
Goceri (2021)	DermNet / DermQuest	Segmentación level-set + DenseNet201	Accuracy 95,24 %	Mismo backbone; segmentación previa en lugar de clasificación directa

El hueco: casi todos los trabajos optimizan Accuracy sobre 7 clases. Ninguno compara el mismo backbone bajo dos estrategias de datos priorizando la sensibilidad clínica.

Objetivos

OBJETIVO GENERAL

Desarrollar y evaluar una comparativa de soluciones basada en Inteligencia Artificial para la clasificación automática de enfermedades dermatológicas a partir de imágenes, contrastando SVM frente a DenseNet201, con el fin de determinar el modelo óptimo y escalable en entornos orientados a la salud.

Objetivos específicos

01

Análisis Exploratorio de Datos

Identificar sesgos y distribuciones de clase sobre HAM10000.

02

Pipeline de preprocesamiento

Redimensionado, normalización y técnicas de balanceo de clases.

03

Pipeline de ML tradicional

Extracción paramétrica de características y clasificador SVM.

04

Pipeline de Deep Learning

Red convolucional entrenada mediante Transfer Learning.

05

Comparativa con criterio clínico

Sensibilidad, F1-Score y AUC-ROC, contrastados con el estado del arte.

Los cinco objetivos específicos se corresponden, uno a uno, con las fases del ciclo CRISP-DM que estructuran la memoria.

02

Metodología

CRISP-DM adaptado a imágenes médicas, diseño experimental y marco normativo

3 minutos · Expone: Christian

CRISP-DM adaptado al análisis de imágenes médicas

Las cinco fases del ciclo estructuran el capítulo 5 de la memoria y esta presentación



Semilla aleatoria fija (42), mismo equipo y mismos criterios de evaluación en todos los experimentos: las diferencias observadas se atribuyen a la estrategia de datos, no al azar.

Diseño experimental: dos algoritmos × dos escenarios de datos

Cuatro experimentos que aíslan el efecto del algoritmo y el efecto de la estrategia de datos

Escenario 1 — dataset multiclase original

Escenario 2 — dataset binario balanceado

SVM

Machine Learning
clásico

7 clases · 10.015 imágenes
PCA (95 %) + SMOTE
StratifiedKFold 5-fold

Benigno/Maligno · 3.908 imágenes
PCA (95 %), sin SMOTE
StratifiedGroupKFold por lesión

DenseNet201

Deep Learning
(Transfer Learning)

7 clases · 10.015 imágenes
Transfer Learning + Data Augmentation
Weighted Cross-Entropy

Benigno/Maligno · 3.908 imágenes
Mismo backbone y mismos hiperparámetros
Sin corrección adicional de desbalance

La comparación decisiva se hace sobre la misma tarea binaria Benigno vs. Maligno: el SVM del Escenario 2 frente a la Cabeza A de DenseNet201.

Marco normativo y ético: viabilidad como CDSS en Ecuador

El trabajo se plantea como Prueba de Concepto académica, pero orientada a su despliegue real

LOPDP	ARCSA	Gobernanza	Ética
Protección de datos - Los datos de salud son datos sensibles (Art. 25, Ley Orgánica de Protección de Datos Personales, Ecuador 2021). - HAM10000 se distribuye con licencia académica abierta y anonimización previa: el riesgo de reidentificación se mitiga casi por completo.	Regulación sanitaria - Un CDSS desplegado en Ecuador requeriría Registro Sanitario de Dispositivo Médico (MSP / ARCSA). - El sistema nunca debe decidir de forma autónoma: siempre bajo criterio final del especialista (human-in-the-loop).	Principios constitucionales - Ecuador no dispone aún de una Ley de IA específica. - Aplican el derecho a la salud integral (Art. 32) y el derecho a no ser discriminado (Art. 11) de la Constitución. - De ahí la exigencia de transparencia algorítmica.	Sesgos demográficos - HAM10000 procede mayoritariamente de poblaciones europeas y australianas: fototipos Fitzpatrick I–III. - La demografía ecuatoriana es predominantemente III–V: reconocer el sesgo es parte del resultado, no una nota al pie.

La conclusión normativa condiciona el resultado técnico: sin validación sobre fototipos locales, el modelo no es desplegable aunque sus métricas sean buenas.

03

Comprensión de los datos

Análisis exploratorio de HAM10000 y las decisiones de modelado que se derivan de él

5 minutos · Expone: Christian

HAM10000: la fuente de datos

Human Against Machine with 10.000 training images — repositorio dermatoscópico de referencia (ISIC 2018)

10.015

Imágenes dermatoscópicas

JPEG en alta resolución

7

Clases diagnósticas

nv · mel · bkl · bcc · akiec · vasc · df

4

Metadatos clínicos

edad · sexo · localización · dx_type

1.956

Lesiones con varias imágenes

exigen partición agrupada por lesion_id

Origen y construcción

- Recopilado durante 20 años en el Departamento de Dermatología de la Universidad Médica de Viena y en una consulta privada de Queensland (Australia).
- Las etiquetas se confirman por histopatología, seguimiento clínico, confocal o consenso de expertos — la variable dx_type registra el método.


Estructura y relaciones

- HAM10000_metadata.csv enlaza cada image_id con su lesion_id, su clase dx y los metadatos del paciente.
- Una misma lesión puede tener varias imágenes: es la relación uno-a-muchos que obliga a controlar la partición para evitar fuga de información.

Un dataset masivo, público y con etiquetas trazables — pero, como veremos, profundamente desequilibrado.

Hallazgo 1 — Un desbalance severo y clínicamente perverso

HAM10000 — 10.015 imágenes · ratio benigno:maligno ≈ 4,1:1



El problema


Las clases más infrarrepresentadas son precisamente las de mayor relevancia clínica: melanoma (11,1 %), carcinoma basocelular (5,1 %) y queratosis actínica (3,3 %).

El clasificador trivial

Un modelo que etiquetase todo como «nevus» alcanzaría un 66,9 % de accuracy sin haber aprendido nada útil.

La distribución no es un artefacto de recopilación: refleja la prevalencia clínica real. Pero obliga a corregir el desbalance y a desconfiar del accuracy.

Hallazgo 2 — La edad es la covariable más informativa



51,85 años

Edad media

DE = 16,93 · mediana 50 años

H = 2.295,31

Kruskal-Wallis

p < 0,0001 entre las 7 clases

r = 0,332

Correlación con
malignidad

moderada pero robusta

Lectura clínica


Las clases malignas asociadas a daño solar crónico —carcinoma basocelular y queratosis actínica— presentan una mediana de 70 años, frente a los 45 años del nevus melanocítico.

La edad acumulada de exposición ultravioleta es uno de los factores de riesgo más robustos para las lesiones malignas de estirpe epidérmica.

Consecuencia: la arquitectura convolucional, que solo procesa píxeles, deja sin explotar información diagnóstica disponible.

Este hallazgo se convierte más adelante en una limitación reconocida del modelado y en la primera línea de trabajo futuro: la fusión multimodal imagen + metadatos.

Hallazgo 3 — Asociaciones entre variables y fuga de datos



Matriz de Cramér's V entre variables categóricas

- malignidad ↔ dx_type V = 0,460**

El método de confirmación diagnóstica está fuertemente asociado a la malignidad: la calidad de las etiquetas es heterogénea según la clase.
- dx ↔ dx_type V = 0,390**

Las clases malignas se confirman por histopatología; las benignas, con frecuencia por seguimiento o consenso.
- malignidad ↔ localización V = 0,280**


Coherente con la etiología: las zonas fotoexpuestas concentran las lesiones por daño solar.
- malignidad ↔ sexo V = 0,080**

Asociación despreciable: el sexo no aporta capacidad discriminativa relevante.

1.956 lesiones tienen más de una imagen: sin partición agrupada por lesion_id, las métricas de validación se inflan artificialmente (Combalia et al., 2019).

Del análisis exploratorio a cuatro decisiones de modelado

Cada hallazgo del EDA se traduce en una decisión concreta que se aplica en las fases siguientes



Estas cuatro decisiones son la bisagra entre el análisis y el modelado: explican por qué construimos dos escenarios de datos en lugar de uno.

04

Preparación de los datos

Limpieza, partición agrupada por lesión y construcción de los dos escenarios

3 minutos · Expone: Alvaro

Pipeline de limpieza y partición

Cuatro pasos comunes a los dos escenarios, aplicados antes de cualquier modelado

01

Limpieza y estandarización

- Normalización de cadenas de texto en las variables categóricas.
- Verificación del rango de edades: valores entre 0 y 85 años.

02

Imputación de valores faltantes

- La variable edad es la única con ausencias relevantes.
- Se imputa preservando la distribución observada por clase diagnóstica.

03

Partición estratificada por lesion_id

- GroupShuffleSplit 80/20 agrupando por lesión.
- Escenario 2: 2.498 lesiones en train y 625 en test, sin solapamiento.

04

Preprocesamiento de imagen

- Redimensionado unificado a 64×64 px RGB para el pipeline SVM.
- Aplanado a un vector de 12.288 características ($64 \times 64 \times 3$) y normalización.

¿Por qué agrupar la partición por lesión y no simplemente estratificar por clase?


Porque 1.956 lesiones del dataset tienen más de una imagen. Con una partición estratificada convencional, imágenes casi idénticas de la misma lesión acaban en entrenamiento y en test simultáneamente: el modelo reconoce la lesión que memorizó, no la patología que debe aprender. El resultado es una inflación artificial de las métricas de validación, documentada en la literatura de clasificación dermatoscópica (Combalia et al., 2019).

Esta partición agrupada se aplica en el Escenario 2 de ambos algoritmos y en la validación cruzada mediante StratifiedGroupKFold.

PREPARACIÓN DE LOS DATOS

Los dos escenarios de datos

Misma fuente, dos formulaciones del problema y dos estrategias de balanceo distintas



Efecto del balanceo sobre la distribución binaria (Figura 11 de la memoria)

¿Por qué se elimina SMOTE en el Escenario 2?

Porque el dataset ya llega equilibrado por submuestreo. Aplicar SMOTE encima generaría muestras sintéticas innecesarias, multiplicaría el coste computacional e introduciría interpolaciones artificiales entre lesiones que no existen clínicamente.

	Escenario 1 — original	Escenario 2 — balanceado
Variable objetivo	dx (7 clases)	Benigno / Maligno
Imágenes de entrada	10.015 (8.061 + 1.954)	3.908 (1.954 + 1.954)
Partición	Estratificada por clase 80/20	GroupShuffleSplit por lesion_id 80/20
Muestras train / test	8.012 / 2.003	3.119 / 789
Lesiones únicas	No controlado	2.498 / 625 sin solapamiento
Balanceo de clases	SMOTE en train (37.548 muestras)	Submuestreo previo, sin SMOTE
Validación cruzada	StratifiedKFold 5-fold	StratifiedGroupKFold 5-fold

El Escenario 2 no es «una versión más pequeña» del Escenario 1: es una reformulación del problema alineada con la decisión clínica real, benigno frente a maligno.

05



Modelado

SVM con kernel RBF y DenseNet201 con arquitectura de dos cabezas

3 minutos · Expone: Alvaro

SVM — la línea base de Machine Learning clásico

Pipeline de 9 pasos: carga → aplanado → normalización → PCA → balanceo → entrenamiento → evaluación



Varianza explicada y acumulada del PCA (Figura 12 de la memoria)

Representación	64×64 px RGB aplanados → 12.288 características por imagen
Reducción	StandardScaler + PCA reteniendo el 95 % de la varianza
Componentes	84 componentes (Esc. 1) · 104 componentes (Esc. 2) — reducción del 99,3 %
Clasificador	SVC con kernel RBF · C = 1,0 · gamma = «scale» · class_weight = «balanced»
Probabilidades	probability = True (Platt scaling), necesario para calcular el AUC
Semilla	42 — CPU Intel i7, 16 GB RAM, sin aceleración GPU

Justificación: SVM fue el estado del arte en imagen médica antes del Deep Learning, es eficiente en alta dimensionalidad y su comportamiento documentado facilita interpretar la mejora.

DenseNet201 — Transfer Learning y dos cabezas

Un único backbone convolucional que optimiza simultáneamente triaje binario y diagnóstico específico

Entrada

Imagen dermatoscópica
+ Data Augmentation
(flips h/v p=0,5 · rot. ±15°)

Backbone DenseNet201

Preentrenado en ImageNet · Bloques densos
Global Average Pooling → vector compartido

Cabeza A — Triage binario

2 neuronas: Benigno vs. Maligno · Cross-Entropy

Cabeza B — Diagnóstico específico

7 neuronas · Weighted Cross-Entropy

Pérdida conjunta

$0,5 \times \text{pérdida binaria} + 0,5 \times \text{pérdida específica}$
Ambas tareas entrenan el mismo backbone

18.110.217

Parámetros entrenables

Transfer Learning desde ImageNet

30 épocas

Batch = 32

Adam · lr = 1e-4 · weight decay = 1e-4

0,5 / 0,5

Pérdida conjunta A + B


ReduceLROnPlateau · factor 0,1 · paciencia 3

62,3 min

Entrenamiento en GPU

130,2 min en el Escenario 1

Curvas de Entrenamiento — DenseNet201



¿Por qué DenseNet201 y por qué dos cabezas?

Los bloques densos conectan cada capa con todas las precedentes: maximizan el flujo de gradientes, mitigan el desvanecimiento y reutilizan características sin disparar el número de parámetros. Las dos cabezas permiten responder a la vez a la pregunta de triaje («¿es sospechosa?») y a la de diagnóstico («¿qué patología es?») con un único coste de entrenamiento.

06

Evaluación y resultados


Qué gana cada estrategia de datos y qué algoritmo responde mejor a la pregunta clínica

6 minutos · Expone: Alvaro

EVALUACIÓN Y RESULTADOS

SVM — El efecto de balancear el dataset

Mismo algoritmo, mismos hiperparámetros y mismo preprocesamiento: solo cambia la estrategia de datos



¿Por qué baja el AUC si todo lo demás mejora?

Porque el AUC mide la capacidad de ordenar los casos a lo largo de todos los umbrales, y se mantiene alto aunque al umbral real de decisión (0,5) el modelo falle en la clase minoritaria.

Lectura de los resultados

Exactitud balanceada

0,517 → 0,794

Deja de estar dominada por la clase mayoritaria.

F1 macro

0,483 → 0,793

Todas las clases pasan a contar por igual.

Cohen's Kappa / MCC

0,450 → 0,593 · 0,456 → 0,614

El acuerdo por encima del azar mejora de forma sólida.

AUC macro

0,878 → 0,864

Única métrica que baja — y la explicación importa.

La validación cruzada 5-fold confirma que la mejora no depende de una partición afortunada: $0,578 \pm 0,007$ frente a $0,787 \pm 0,015$ en accuracy.

SVM — ¿Detecta realmente la malignidad?

La línea base de 7 clases se agrega a binario para poder responder en los mismos términos

Modelo	Real	Predicho: Benigno	Predicho: Maligno
Línea base (agregada a binario)	Benigno (1.612)	1.321	291
Línea base (agregada a binario)	Maligno (391)	139 falsos negativos	252
Balanceado (binario nativo)	Benigno (381)	251	130
Balanceado (binario nativo)	Maligno (408)	29 falsos negativos	379

64,5 % → 92,9 %


Sensibilidad (recall Maligno)

casi se triplican las malignidades detectadas

81,9 % → 65,9 %

Especificidad (recall Benigno)

el precio: más falsas alarmas



El caso del melanoma en la línea base

Su AUC one-vs-rest es 0,827 —una cifra aparentemente aceptable—, pero su recall real es 0,475: el modelo no detecta más de la mitad de los melanomas del test, confundiéndolos sobre todo con nevus (62 casos) y queratosis benigna (36 casos).


Es exactamente el intercambio buscado: sacrificar especificidad —que cuesta una consulta adicional— para casi triplicar la detección de malignidad, que es el error que no se puede cometer.

DenseNet201 — Cabeza A: el mismo efecto en la red

El balanceo desplaza el punto de operación hacia la sensibilidad sin alterar la discriminación subyacente


Métrica — Cabeza A	Escenario 1	Escenario 2
Accuracy	93,36 %	91,43 %
Balanced Accuracy	88,71 %	91,43 %
Sensibilidad (Recall Maligno)	81,07 %	90,03 %
Especificidad (Recall Benigno)	96,34 %	92,84 %
Precisión (Maligno)	84,31 %	92,63 %
F1 Macro	89,28 %	91,43 %
AUC-ROC	96,46 %	96,50 %
Average Precision	89,70 %	96,00 %
Cohen's Kappa / MCC	0,786	0,829

Escenario 1 — dataset original



74 falsos negativos de 391 malignas (18,9 %)

Escenario 2 — dataset balanceado



39 falsos negativos de 391 malignas (10,0 %)

La lectura clave


Sobre las mismas 391 lesiones malignas de validación, los falsos negativos caen de 74 (18,9 %) a 39 (10,0 %): se reducen casi a la mitad.

El AUC-ROC se mantiene prácticamente constante (96,46 % → 96,50 %): la capacidad de discriminación apenas cambia. Lo que el balanceo mueve es el punto de operación del clasificador, no lo que la red ha aprendido.

El efecto observado con SVM se reproduce con DenseNet201: balancear el dataset es una decisión de datos, no un artefacto de un algoritmo concreto.

DenseNet201 — Cabeza B: el trade-off que el balanceo introduce

Lo que beneficia al triaje binario perjudica al diagnóstico específico de las siete patologías



Cabeza B	Esc. 1	Esc. 2
Accuracy	90,36 %	86,96 %
Recall Macro	87,78 %	78,13 %
Precision Macro	85,99 %	81,86 %
F1 Macro	86,79 %	79,71 %
AUC Macro	98,44 %	97,88 %
Kappa / MCC	0,816	0,815

Melanoma: única clase que mejora, +12,11 puntos (73,99 % → 86,10 %)

Las caídas más severas —dermatofibroma (−31,30) y lesión vascular (−13,10)— son las clases benignas que el submuestreo reduce a 18 y 24 muestras, frente a 92 y 114 en el Escenario 1.

El caso llamativo: akiec


Pierde 18,46 puntos de recall pese a conservar exactamente las mismas 262 muestras de entrenamiento. Su peso de clase cae de 4,37 a 1,70 al recalcularse sobre un conjunto más pequeño.

Los dos escenarios son óptimos para propósitos clínicos distintos: el Escenario 1 para cribado masivo; el Escenario 2 para segunda opinión oncológica.

Cara a cara: SVM vs. DenseNet201 sobre la misma tarea binaria

Ambos representados por su mejor configuración — el Escenario 2 — y evaluados con el mismo criterio de éxito

Dimensión	SVM — Esc. 2	DenseNet201 — Esc. 2 (Cabeza A)
Conjunto de evaluación	789 imágenes (agrupadas por lesión)	782 imágenes de validación
Accuracy global	79,85 %	91,43 %
Sensibilidad (Recall Maligno)	92,90 %	90,03 %
Especificidad (Recall Benigno)	65,90 %	92,84 %
Precisión (Maligno)	74,50 %	92,63 %
F1 (Maligno)	0,827	0,913
AUC-ROC	86,43 %	96,50 %
Cohen's Kappa / MCC	0,593 / 0,614	0,829 / 0,829
Tiempo de entrenamiento	1,33 s	3.737,6 s (62,3 min)
Inferencia por imagen	0,25 ms	13,35 ms




La Sensibilidad es la única dimensión en la que gana el SVM, y por 2,87 puntos. DenseNet201 domina en todo lo demás.


El coste de esa ventaja: cómputo frente a capacidad asistencial

La decisión de despliegue no depende solo de qué métrica gane en una tabla

Tiempo de entrenamiento (escala log)



Inferencia por imagen



El orden de magnitud

DenseNet201 es miles de veces más lento en entrenamiento y decenas de veces más lento en inferencia. En complejidad efectiva aprendida, el SVM balanceado reduce sus vectores de soporte de 20.944 a 1.758 respecto de la línea base.

Si el recurso escaso es el cómputo

El SVM entrena en 1,33 segundos e infiere en 0,25 ms por imagen. Es viable en un centro de salud sin GPU y ofrece la sensibilidad agregada más alta de las dos opciones.

Si el recurso escaso es el especialista

La especificidad del 65,9 % del SVM implica derivar a consulta a una proporción muy alta de pacientes sanos. DenseNet201, con sensibilidad casi equivalente, evita ese colapso de las derivaciones.

07

Conclusiones y prospectiva

Cumplimiento de objetivos, conclusiones, limitaciones y líneas de trabajo futuro

2 minutos · Expone: Alvaro

Cumplimiento de objetivos y conclusiones principales

Objetivo	Evidencia	Estado
Realizar el EDA	Cap. 5.2	Cumplido
Preparar y balancear los datos	Cap. 5.3	Cumplido
Implementar SVM	Cap. 5.4.2-3 · 5.5.2-3	Cumplido
Implementar DenseNet201	Cap. 5.4.4-5 · 5.5.4-5	Cumplido
Comparar los modelos	Cap. 5.5.6	Cumplido

Reproducibilidad

Todo el código —ingesta, EDA, preprocesamiento, SVM y DenseNet201— está versionado en GitHub, con métricas exportadas a Excel y JSON y los modelos serializados.

github.com/marzo27/UNIR_TFM_HAM10000

01 No hay un ganador absoluto

El SVM del Escenario 2 ofrece la sensibilidad agregada más alta (92,9 %) a coste computacional casi nulo. DenseNet201 ofrece una sensibilidad casi equivalente (90,03 %) con especificidad, precisión, AUC-ROC y Kappa muy superiores.

02 Balancear el dataset desplaza el punto de operación

El efecto se reproduce en los dos algoritmos: sube la sensibilidad, baja la especificidad y el AUC-ROC apenas se mueve. No cambia lo que el modelo aprende, sino dónde decide.

03 Las dos cabezas responden a necesidades clínicas distintas

El Escenario 1 maximiza el diagnóstico específico entre las siete patologías y encaja en cribado masivo. El Escenario 2 reduce los falsos negativos a la mitad y encaja en segunda opinión oncológica.

04 La decisión de despliegue es contextual

Depende de qué recurso sea más escaso en el punto de uso: el cómputo disponible o la capacidad de atención especializada para revisar las derivaciones del sistema.

Limitaciones reconocidas y líneas de trabajo futuro

Limitaciones

Sesgo fenotípico y demográfico

HAM10000 procede de poblaciones europeas y australianas (fototipos I–III). La demografía ecuatoriana es predominantemente III–V: falta representatividad étnica local.

Exclusión de las variables clínicas auxiliares

La red opera solo sobre píxeles: no integrar edad, sexo y localización deja sin explotar la señal que el propio EDA identificó como informativa.

Infrarrepresentación de subtipos críticos

El melanoma acral lentiginoso, de altísima mortalidad local, está severamente infrarrepresentado en la muestra de entrenamiento.

Partición del Escenario 1 de DenseNet201

Se realizó estratificada por clase, sin agrupar por lesion_id. El Escenario 2 sí aplica el agrupamiento.

La limitación más relevante no es técnica sino de representatividad: sin validación sobre fototipos locales, ningún resultado de esta memoria es directamente trasladable a la clínica ecuatoriana.

Trabajo futuro

Muestreo asimétrico por cabeza lineal

Alimentar cada cabeza con un lote distinto en el mismo ciclo: la Cabeza A con el dataset balanceado y la Cabeza B con el original, para resolver el trade-off observado.

Modelado multimodal integrado

Fusionar el vector visual de DenseNet201 con una red densa que procese edad, sexo y localización anatómica.

Arquitecturas alternativas

Evaluar EfficientNet y Vision Transformers frente a DenseNet201 en relación precisión / coste.

Validación multicéntrica e integración CDSS

Validar sobre datos de centros ecuatorianos e integrar el modelo en el flujo de trabajo real del dermatólogo, con trazabilidad de las decisiones.

muchas gracias

Evaluación comparativa de SVM y DenseNet201 para la clasificación automática de enfermedades dermatológicas

Christian Marcelo Gutiérrez Gutiérrez · Alvaro Marcelo Gutiérrez Burbano

Director: Víctor D. Díaz Suárez · github.com/marzo27/UNIR_TFM_HAM10000